

Hệ Thống Tự Động Mã Hóa Định Danh Trong Văn Bản

Trần Quang Minh

Trung tâm Không gian mạng Viettel
minhtq21@viettel.com.vn

Đoàn Xuân Dũng

Trung tâm Không gian mạng Viettel
dungdx4@viettel.com.vn

Tóm tắt

Bản án là văn bản được đưa ra để ghi nhận phán quyết của Tòa án sau khi xét xử một vụ án. Nội dung của một bản án có thể chứa nhiều thông tin về những người liên quan đến vụ án như tên, địa chỉ của các nguyên đơn, bị cáo,... Do đó, khi công khai các bản án này ra cho công chúng, những thông tin này cần được ẩn đi vì lý do bảo mật cũng như bảo vệ quyền lợi của những người có liên quan đến vụ án. Trong báo cáo này, chúng tôi sẽ xây dựng một số mô hình Học sâu, kết hợp với một số phương pháp xử lý sâu để giải quyết vấn đề trên. Phương pháp mà chúng tôi đề xuất đã cho kết quả cải thiện hơn các phương pháp triển khai trước đó tại Trung tâm Không gian mạng Viettel, và đã được đóng gói thành API để có thể tích hợp thành một chức năng của sản phẩm Trợ lý ảo tòa án.

1 Giới thiệu

Hiện nay, sau khi xét xử mỗi vụ án, Tòa án sẽ đưa ra một văn bản để ghi nhận các phán quyết, gọi là Bản án. Bản án đánh dấu sự kết thúc toàn bộ quá trình điều tra, truy tố, xét xử, nên nội dung của nó phải phản ánh những kết quả của phiên tòa và ý kiến phân tích, đánh giá của hội đồng xét xử. Nội dung của bản án chứa nhiều thông tin về những người liên quan đến vụ án như tên, địa chỉ,... Do đó, khi công khai các bản án này ra cho công chúng, những thông tin này cần được ẩn đi vì lý do bảo mật, cũng như bảo vệ quyền lợi của những người có liên quan đến vụ án. Ví dụ với câu "Anh Phạm Văn Hoàng, trú tại phường Láng Hạ, quận Đống Đa, thành phố Hà Nội đã phạm tội trộm cắp" thì các thông tin liên quan đến nhân vật xuất hiện trong vụ án nên được ẩn đi, có thể là "Anh Phạm Văn H, trú tại phường L, quận Đ, thành phố H đã phạm tội trộm cắp". Việc ẩn đi các thông tin trên có thể được thực hiện thủ công bởi con người, tuy nhiên sẽ gây tốn kém nhiều chi phí. Trong khi đó,

vấn đề trên có thể được giải quyết bằng cách đưa về một số bài toán trong lĩnh vực Xử lý ngôn ngữ tự nhiên.

Để có thể giải quyết bài toán trên, chúng tôi sẽ thực hiện thông qua hai giai đoạn: Phát hiện tên người và địa điểm trong bản án (1) và Mã hóa tên người và địa điểm đã phát hiện theo yêu cầu (2). Giai đoạn (1) có thể được giải quyết bằng cách đưa về bài toán Nhận dạng thực thể có tên (Named Entity Recognition - NER), trong khi ở giai đoạn (2), chúng tôi xây dựng thuật toán ánh xạ các tên người cùng đề cập đến một đối tượng và thuật toán mã hóa tên địa điểm, từ đó sinh ra được những quy tắc mã hóa phù hợp theo yêu cầu của bài toán.

2 Định nghĩa bài toán

Yêu cầu cụ thể của bài toán là mã hóa tên người và địa điểm trong các Bản án. Tuy nhiên, bài toán chỉ yêu cầu mã hóa thông tin của những người liên quan đến vụ án như bị cáo, nguyên đơn, nạn nhân,... và không mã hóa các thông tin của Thẩm phán, Thư ký,... Với tên người, ta chỉ mã hóa tên riêng (không mã hóa họ và tên đệm) bằng ký tự đầu tiên trong tên, ví dụ "Phạm Quang Linh" sẽ được mã hóa là "Phạm Quang L". Tuy nhiên, có một vấn đề với cách mã hóa này khi hai tên riêng có cùng ký tự đầu tiên, ví dụ "Lan" và "Linh", thì ký tự đại diện là giống nhau (đều là "L"), dẫn đến trong nhiều ngữ cảnh, ta không thể phân biệt được hai đối tượng này. Do đó, với những trường hợp này, bài toán yêu cầu thêm các chữ số để phân biệt các đối tượng, ví dụ nếu "Lan" đã được mã hóa là "L", thì "Linh" cần được mã hóa là "L1",... Việc đánh số có thể dựa trên thứ tự xuất hiện của đối tượng trong văn bản. Với tên địa điểm (quận, huyện, tỉnh,...), ta thực hiện mã hóa bằng chữ cái đầu tiên trong tên địa điểm đó nếu tên địa điểm gồm các chữ cái, hoặc bằng ký tự "X" nếu tên địa điểm là các chữ số. Ví dụ với đầu vào

là câu "Nguyễn Thị Lan, Phạm Thị Linh và Trần Văn Quang, cùng trú tại phường 1, quận Đống Đa, thành phố Hà Nội đã phạm tội trộm cắp. Lan và Linh đã thừa nhận tội danh của mình, nhưng Quang thì không", thì đầu ra tương ứng theo yêu cầu là "Nguyễn Thị L, Phạm Thị L1 và Trần Văn Q, cùng trú tại phường X, quận Đ, thành phố H đã phạm tội trộm cắp. L và L1 đã thừa nhận tội danh của mình, nhưng Q thì không".

Thách thức mà chúng tôi gặp phải khi thực hiện bài toán trên là không có tập dữ liệu bản án được gán nhãn để huấn luyện mô hình phát hiện tên người và địa điểm. Ngoài ra, với yêu cầu không mã hóa các thông tin liên quan đến Thẩm phán, Thư ký,..., thì để phân biệt thông tin của những người này với những người cần mã hóa thông tin cũng là một nhiệm vụ rất khó khăn.

3 Các hướng tiếp cận

3.1 Nhận dạng thực thể có tên

Dễ thấy kết quả của giai đoạn (1), tương ứng với bài toán Nhận dạng thực thể có tên sẽ ảnh hưởng lớn đến kết quả tổng thể của bài toán. Đây là một bài toán quan trọng trong Xử lý ngôn ngữ tự nhiên, thuộc lớp bài toán Gán nhãn chuỗi (Sequence Labeling). Có nhiều cách tiếp cận cho bài toán này, đơn giản nhất là xây dựng tập các luật từ đặc trưng của từng loại thực thể để phát hiện ra chúng. Tuy nhiên với các văn bản và thực thể phức tạp thì việc xây dựng được tập luật là rất khó khăn. Do đó, phương pháp phổ biến nhất hiện nay là huấn luyện các mô hình học máy từ một tập dữ liệu đã gán nhãn để tự động phát hiện ra tên các thực thể.


Đã có những nghiên cứu đề xuất một số phương pháp Học máy dựa trên xác suất như sử dụng Mô hình Markov ẩn (Hidden Markov Model) (Zhou and Su, 2002) hay Trường điều kiện ngẫu nhiên (Conditional Random Field) (McCallum and Li, 2003) để học được khả năng các từ hoặc cụm từ là tên thực thể xuất hiện trong ngữ cảnh, hoặc từ những đặc trưng mà từ hoặc cụm từ đó có. Trong khi đó, phương pháp dựa trên Học sâu thường áp dụng các mô hình từ đầu vào gồm các câu để học được mối quan hệ về cú pháp cũng như ngữ nghĩa giữa các từ để dự đoán ra tên các thực thể. Các mô hình mạng neuron hồi quy thường được áp dụng cho bài toán do tính chất của các mô hình này phù hợp với kiểu dữ liệu dạng chuỗi như văn bản. Để thấy mối quan hệ về ngữ nghĩa và cú pháp của các từ không chỉ tuân theo một chiều duy nhất, nên người ta thường áp dụng các mô hình mạng hai

chiều (Chiu and Nichols, 2016) để học được nhiều thông tin trong chuỗi hơn, từ đó đưa ra được những dự đoán về tên thực thể tốt hơn.

Với sự ra đời của các mô hình ngôn ngữ tiên tiến như BERT (Devlin et al., 2019), RoBERTa (Liu et al., 2019),..., nhiều tác vụ Xử lý ngôn ngữ tự nhiên đã đạt được những kết quả đột phá, trong đó có tác vụ Nhận dạng thực thể có tên. BERT được công bố bởi Google năm 2018 được xây dựng dựa trên nhiều tầng Transformer Encoder hai chiều, huấn luyện trên những bộ dữ liệu kích thước lớn với hai tác vụ là Masked Language Model (MLM) và Next Sentence Prediction (NSP). RoBERTa được công bố bởi Facebook năm 2019 có thể coi như là một phiên bản tối ưu của BERT, khi được huấn luyện với dữ liệu kích thước lớn hơn, cũng như tinh chỉnh một vài chi tiết, nổi bật nhất là bỏ đi tác vụ NSP trong quá trình huấn luyện. Việc áp dụng các mô hình ngôn ngữ này cho bài toán nhận dạng thực thể có tên được thực hiện bằng cách thêm một hoặc một số tầng tuyến tính sau biểu diễn ẩn của mỗi token để dự đoán xem token đó có phải là một thành phần của tên thực thể hay không.

Từ những kết quả đột phá của các mô hình ngôn ngữ trên tiếng Anh, liên tục có những công bố về mô hình ngôn ngữ cho nhiều ngôn ngữ khác nhau, trong đó có tiếng Việt. Các mô hình này được xây dựng và huấn luyện tương tự như các mô hình cho tiếng Anh. PhoBERT (Nguyen and Nguyen, 2020) được công bố bởi VinAI Research là mô hình ngôn ngữ đầu tiên cho tiếng Việt, đã đạt được những kết quả state-of-the-art cho nhiều tác vụ. Cách cài đặt và huấn luyện PhoBERT được thực hiện tương tự như RoBERTa, với dữ liệu có kích thước khoảng 20GB về những chủ đề như tin tức, báo chí. Tương tự, Trung tâm Không gian mạng Viettel cũng huấn luyện một mô hình ngôn ngữ cho tiếng Việt, được đặt tên là VTCC-RoBERTa, cũng dựa trên kiến trúc của RoBERTa với dữ liệu có kích thước khoảng 70GB về những chủ đề tin tức, báo chí, luật pháp, mạng xã hội, chatbot.

Những kết quả tốt nhất hiện nay cho bài toán thường kết hợp nhiều phương pháp đã trình bày phía trên. Mô hình LSTM-CRF (Huang et al., 2015), LM-LSTM-CRF (Liu et al., 2018) được đề xuất sử dụng mạng LSTM để trích xuất đặc trưng từ các token, sau đó kết hợp với tầng Conditional Random Field (CRF) để làm đầu ra. Gần đây, các nghiên cứu tập trung áp dụng các mô hình ngôn ngữ để trích xuất đặc trưng, làm đầu vào



Hình 1: Mô hình cho bài toán

cho các mô hình học sâu, kết hợp với tầng CRF để thực hiện huấn luyện mô hình như BERT-CRF, RoBERTa-CRF (Souza et al., 2019).

3.2 Mã hóa tên thực thể

Việc lựa chọn các phương pháp mã hóa tên thực thể sẽ phụ thuộc vào yêu cầu của từng bài toán, cũng như đặc điểm của các tên thực thể. Với những yêu cầu mã hóa đơn giản, ví như việc mã hóa tên địa điểm trong bài toán mà chúng tôi thực hiện, ta có thể xây dựng một tập hợp các luật để phù hợp với yêu cầu. Tuy nhiên trong những trường hợp yêu cầu mức độ mã hóa cao hơn và tính đồng nhất về các thực thể có nhiều tên gọi khác nhau, việc mã hóa có thể cần được kết hợp với bài toán liên kết thực thể (entity linking), ví dụ như việc mã hóa tên người trong bài toán mà chúng tôi thực hiện. Bài toán liên kết thực thể có thể được xây dựng dựa trên tập hợp các luật nếu các tên thực thể đơn giản, hoặc huấn luyện một mô hình từ dữ liệu được gán nhãn trong những trường hợp phức tạp hơn.

4 Phương pháp thực hiện

4.1 Phát hiện tên người và địa điểm

Hình 1 mô tả mô hình mà chúng tôi sử dụng cho bài toán Nhận dạng thực thể có tên. Các mô hình ngôn ngữ được áp dụng từ đầu vào để thu được chuỗi biểu diễn ẩn của các token, sau đó kết hợp với tầng CRF để phân loại xem token đó thuộc về nhãn thực thể nào. Với đầu vào gồm n token, các mô hình ngôn ngữ sẽ biểu diễn mỗi token bằng một vector H chiều. Sau đó, mô hình ánh xạ biểu diễn ẩn của mỗi token sang không gian vector mới với số chiều là K , với K là số nhãn thực thể của bài toán, được biểu diễn bằng ma trận $\mathbf{P} \in \mathbb{R}^{n \times K}$. Ma trận $\mathbf{P}$ sau đó được đưa vào tầng CRF, với tham số tương ứng là ma trận $\mathbf{A} \in \mathbb{R}^{(K+2) \times (K+2)}$, gọi là

ma trận chuyển đổi nhãn. Phần tử $A_{i,j}$ tương ứng trong ma trận $\mathbf{A}$ biểu diễn trọng số chuyển đổi từ nhãn i sang nhãn j . Ngoài K nhãn thực thể trong bài toán, $\mathbf{A}$ thêm hai nhãn khác là *start* và *end*, tương ứng với trạng thái bắt đầu và kết thúc chuỗi.

Khi đó với đầu vào $\mathbf{X} = (x_1, \dots, x_n)$ và nhãn dự đoán tương ứng $\mathbf{y} = (y_1, \dots, y_n)$ thì điểm cho dự đoán tương ứng với chuỗi được định nghĩa bởi công thức:

$$s(\mathbf{X}, \mathbf{y}) = \sum_{i=0}^n A_{y_i, y_{i+1}} + \sum_{i=1}^n P_{i, y_i} \quad (1)$$

với y_0 và y_{n+1} là nhãn *start* và *end*. Mô hình được huấn luyện để tối đa hóa giá trị xác suất log của chuỗi nhãn chuẩn:

$$\log p(\mathbf{y}|\mathbf{X}) = s(\mathbf{X}, \mathbf{y}) - \log \sum_{\hat{\mathbf{y}} \in \mathbf{Y}_{\mathbf{X}}} \exp(s(\mathbf{X}, \hat{\mathbf{y}})) \quad (2)$$

với $\mathbf{Y}_{\mathbf{X}}$ là tập tất cả các chuỗi nhãn có thể có.

4.2 Mã hóa tên người và địa điểm

4.2.1 Ánh xạ tên người

Sau khi đã phát hiện được các tên người, ta cần ánh xạ các tên này để phát hiện các tên cùng đề cập đến cùng một đối tượng, từ đó xây dựng bộ quy tắc mã hóa tên phù hợp ở bước tiếp theo. Quá trình ánh xạ tên người được mô tả trong thuật toán 1. Thuật toán nhận đầu vào là danh sách tên người, trong đó mỗi phần tử sẽ tương ứng là một từ điển với các khóa và giá trị tương ứng như sau:

- *word*: xâu tương ứng tên người
- *start_index*: vị trí bắt đầu tên trong văn bản
- *end_index*: vị trí kết thúc tên trong văn bản

Algorithm 1: Thuật toán ánh xạ tên người

```
1 Function MapPersonName (per_lst) :
2   n ← per_lst.size()
3   mark ← [-1, ..., -1] // n phần tử
4   for i ← 0 to n - 1 do
5     for j ← i to n - 1 do
6       // Kiểm tra xâu con
7       if mark[j] = -1 then
8         if per_lst[j][word] isSubstring per_lst[i][word] then
9           mark[j] ← i // Đánh dấu hai tên cùng ánh xạ đến một người
10
11   dict_map_name ← {}
12   for i ← 0 to n - 1 do
13     if mark[j] not in dict_map_name then
14       dict_map_name[mark[i]] ← [per_lst[i]]
15     else
16       dict_map_name[mark[i]]
17         .append(per_lst[i])
18   return dict_map_name
```

Các phần tử trong danh sách đã được sắp xếp theo thứ tự xuất hiện trong văn bản, tức theo thứ tự tăng dần của *start_index*. Thông thường, bản án sẽ đề cập đến tên đầy đủ của một người trước khi nhắc lại họ bằng tên riêng ở những phần phía sau, nên với các tên người cùng đề cập đến đối tượng thì tên sau sẽ là tên đầu hoặc tên đệm và tên đầu của người đó. Do đó với mỗi tên, chúng tôi sẽ xét tất cả các tên ở phía sau trong danh sách và kiểm tra xem chúng có phải là xâu con của tên đang xét hay không. Nếu có, chúng tôi gán hai tên này cùng ánh xạ đến một người, được đánh dấu bởi mảng *mark*. Mảng *mark* ở hai vị trí *i* và *j* sẽ có giá trị bằng nhau nếu hai giá trị *per_lst*[*i*][*word*] và *per_lst*[*j*][*word*] cùng ánh xạ đến một người và ngược lại. Từ đây, thuật toán sẽ trả về một từ điển với giá trị ứng với mỗi khóa là một danh sách, các phần tử trong cùng một danh sách cùng ánh xạ đến một người. Ở mỗi danh sách, các phần tử cũng đều được sắp xếp theo thứ tự xuất hiện trong văn bản.

4.2.2 Mã hóa tên người

Sau khi đã ánh xạ các tên người, chúng tôi xây dựng bộ quy tắc mã hóa phù hợp với yêu cầu của bài toán. Cần lưu ý rằng bài toán không yêu cầu mã hóa tên của các thành phần như Thẩm phán, Thư ký phiên tòa, Kiểm soát viên,... Do đó trước tiên, chúng tôi sẽ tìm các khoảng vị trí chứa tên của những người này. Sau khi đã quan sát một số

bản án, chúng tôi xác định được bốn thành phần thường xuất hiện trong một bản án gồm Chủ tọa, Hội thẩm nhân dân, Thư ký và Kiểm sát viên. Việc tìm ra các khoảng vị trí chứa tên bốn thành phần này có thể tương ứng dựa trên vị trí của các xâu "chủ tọa", "hội thẩm nhân dân", "thư ký", "kiểm sát viên" trong văn bản. Tuy nhiên, việc tìm các khoảng vị trí này chỉ mang tính chất tương đối, và cũng chỉ giải quyết được phần nào yêu cầu trên. Đây là một yêu cầu nâng cao của bài toán, cần được nghiên cứu thêm trong tương lai để đạt được kết quả tốt nhất.

Thuật toán 2 mô tả chi tiết quy tắc ẩn mã hóa tên người mà chúng tôi xây dựng, với đầu vào là từ điển đã thu được ở thuật toán 1. Mỗi danh sách ứng với mỗi khóa chúng tôi chọn ra phần tử đầu tiên và kiểm tra chúng có nằm trong các khoảng vị trí mà chúng tôi đã định nghĩa ở phía trên (hàm CheckPos). Nếu có, thuật toán sẽ bỏ qua các tên này do nhiều khả năng chúng là tên các đối tượng mà bài toán không yêu cầu mã hóa. Ngược lại, thuật toán sẽ xác định được tên riêng, từ đó dễ dàng xác định được ký tự đại diện cho tên người này. Để tránh trường hợp hai tên người khác nhau có cùng ký tự đại diện, chúng tôi sử dụng từ điển *character*. Khi một ký tự lần đầu được sử dụng để mã hóa, nó sẽ được thêm vào làm khóa mới của *character* với giá trị tương ứng là 0. Ngược lại, khi đã ký tự này đã được sử dụng trước đó và tiếp tục được sử dụng

Algorithm 2: Thuật toán mã hóa tên người

```
1 Function HidePersonName (dict_map_name) :  
2   character  $\leftarrow \{\}$   
3   res  $\leftarrow []$   
4   for key  $\in$  dict_map_name do  
5     per_lst  $\leftarrow$  dict_map_name[key]  
6     // Kiểm tra vị trí tên người  
7     if CheckPos (per_lst[0]) then  
8       continue  
9     first_names  $\leftarrow$  per_lst[0][word].split()[−1] // Xác định tên riêng  
10    c  $\leftarrow$  first_name[0]  
11    if c  $\in$  character then  
12      character[c]  $\leftarrow$  character[c] + 1  
13      c  $\leftarrow$  c + character[c].toString()  
14    else  
15      character[c]  $\leftarrow$  0  
16    n  $\leftarrow$  per_lst.size()  
17    // Thay thế tên riêng bằng xâu mã hóa ở toàn bộ các tên trong danh sách  
18    for i  $\leftarrow$  0 to n − 1 do  
19      first_name  $\leftarrow$  per_lst[i][word].split()[−1]  
20      len  $\leftarrow$  first_name.length()  
21      per_lst[i][word]  $\leftarrow$  per_lst[i][word][: len]  
22      per_lst[i][word]  $\leftarrow$  per_lst[i][word] + c  
23    res.extend(dict_map_name[key])  
24  return res
```

ở thời điểm đang xét, thì giá trị tương ứng với khóa sẽ được cộng thêm 1, và khi dùng để ẩn danh cho tên người thì ký tự đại diện sẽ được nối thêm giá trị tương ứng với ký tự đó, ví dụ với khóa "L" khi có giá trị 2, thì xâu mã hóa là tương ứng "L2". Thuật toán 2 sau cùng trả về danh sách các tên người đã được mã hóa, theo thứ tự xuất hiện trong bản án.

4.2.3 Mã hóa tên địa điểm

Bài toán cũng không yêu cầu mã hóa các thông tin về địa điểm liên quan đến Thẩm phán, Thư ký,... Do đó tương tự như phần 4.2.2, chúng tôi cũng xác định các khoảng vị trí trong văn bản nhiều khả năng chứa tên thực thể địa điểm liên quan đến những đối tượng này, và thực hiện kiểm tra vị trí tương tự như đã trình bày.

Thuật toán 3 trình bày cụ thể phương pháp mã hóa tên địa điểm mà chúng tôi đề xuất, với đầu vào là danh sách các phần tử ứng với các tên địa điểm, và có cấu trúc tương tự như các phần tử ứng với tên người, tức đều gồm các khóa *word*, *start_index* và *end_index*. Hầu hết các tên địa

điểm đều có dạng "loại_địa_điểm tên_địa_điểm", ví dụ như "phường Mễ Trì", trong đó "phường" là loại địa điểm, "Mễ Trì" là tên địa điểm. Do đó, chúng tôi xây dựng một tập hợp *L* gồm các loại địa điểm, chẳng hạn như "phường", "xã", "quận",... Với mỗi tên địa điểm, chúng tôi xét từng từ theo thứ tự từ trái qua phải. Nếu từ đang xét nằm trong tập *L* thì bỏ qua và xét đến từ tiếp theo. Ngược lại, từ đang xét nhiều khả năng là từ bắt đầu tên riêng của địa điểm, do đó chúng tôi lấy ký tự đầu tiên của từ này làm ký tự đại diện nếu ký tự đó là chữ cái, hoặc dùng ký tự "X" làm ký tự đại diện nếu ký tự đó là chữ số.

5 Thực nghiệm

5.1 Dữ liệu

Như đã trình bày ở phần 2, chúng tôi không được cung cấp các bản án được gắn nhãn tên người và địa điểm. Do đó, chúng tôi sẽ huấn luyện mô hình phát hiện tên người và địa điểm dựa trên bộ dữ liệu đã được gắn nhãn ở những chủ đề như tin tức, báo chí, mạng xã hội,... từ đó áp dụng cho dữ liệu bản

Algorithm 3: Thuật toán mã hóa tên địa điểm

```
1 Function HideLocationName (loc_lst) :  
2   n ← loc_lst.size()  
3   for i ← 0 to n − 1 do  
4     loc_tmp ← loc_lst[i]  
      // Kiểm tra vị trí tên địa điểm  
5     if CheckPos (loc_tmp) then  
6       continue  
7     words ← word_tokenize(loc_tmp[word]) // Tách từ  
8     tmp_words ← []  
9     for word ∈ words do  
10      if word ∈ L then  
11        tmp_words.append(word)  
12      else  
13        if word[0].isDigit() then  
14          tmp_words.append(X)  
15        else  
16          tmp_words.append(words[0])  
17      loc_name ← space.join(tmp_words) // Nối lại tên bằng khoảng trắng  
18      loc_lst[i][word] ← loc_name  
19 return loc_lst
```

án. Bộ dữ liệu mà chúng tôi sử dụng cho bài toán tận dụng từ dự án Nhận dạng thực thể có tên mà Trung tâm Không gian mạng Viettel đã thực hiện trước đó với một số loại thực thể như tên người (PER), tên địa điểm (LOC), tên tổ chức (ORG),... Một số chi tiết về bộ dữ liệu này được trình bày trong bảng 1.

Bảng 1: Thống kê dữ liệu huấn luyện

Train	Dev	Test	Số loại thực thể	Số lớp
43081	9573	13341	23	47

Để xây dựng dữ liệu kiểm thử, trước tiên, chúng tôi khôi phục lại tên người và địa điểm của một số bản án được cung cấp. Ví dụ, tên người “Nguyễn Quang L” có thể được khôi phục lại là “Nguyễn Quang Linh”, các tên địa điểm như “phường M”, “quận C”, “thành phố H” có thể được khôi phục lại tương ứng là “phường Mỹ Đình”, “quận Cầu Giấy”, “thành phố Hà Nội”. Từ đây, chúng tôi thực hiện gán nhãn thực thể theo từng từ của các bản án đã được khôi phục tên. Do hạn chế về thời gian, chúng tôi chỉ thực hiện gán nhãn 17 bản án, bao gồm 821 câu. Bộ dữ liệu đã được gán nhãn này được sử dụng làm dữ liệu kiểm thử để chọn ra mô hình có kết quả tốt nhất cho giai đoạn (1).

5.2 Chiến lược gán nhãn dữ liệu huấn luyện

Dữ liệu huấn luyện chúng tôi được cung cấp gán nhãn theo mức từ theo cấu trúc B-I-O, rất phổ biến trong các bài toán về Gán nhãn chuỗi.

Bài toán chỉ yêu cầu nhận dạng hai loại thực thể là tên người và tên địa điểm. Trong khi đó dữ liệu huấn luyện lại được gán nhãn với số loại thực thể là 23 loại và có chứa hai kiểu thực thể trên. Vì vậy, nếu chỉ huấn luyện các mô hình trên dữ liệu gán nhãn này thì kết quả có thể sẽ không tốt, do mô hình phải học dự đoán quá nhiều loại thực thể. Do đó, chúng tôi sẽ tiến hành huấn luyện mô hình trên dữ liệu với những chiến lược gán nhãn khác nhau, cụ thể:

- ALL: Nhãn thực thể gốc với 23 loại thực thể và 47 nhãn.
- PER_LOC: Chỉ giữ lại hai loại thực thể PER và LOC (các loại thực thể con của LOC đều được chuyển về LOC), các loại thực thể khác được chuyển toàn bộ về nhãn O. Như vậy chiến lược này chỉ có 2 loại thực thể và 5 nhãn.
- PER_LOC_MISC: Giữ lại hai loại thực thể PER và LOC (các loại thực thể con của LOC

Bảng 2: Kết quả Nhận dạng thực thể có tên (F1 Score)

	LM-LSTM-CRF	PhoBERT-CRF	VTCC-RoBERTa-CRF
ALL	98.13	97.51	97.06
PER_LOC	-	97.61	98.52
PER_LOC_MISC	-	97.28	97.64
PER_LOC_FIX	-	98.55	98.95

đều được chuyển về LOC), các loại thực thể khác được chuyển toàn bộ về MISC (loại thực thể khác). Như vậy chiến lược này có 3 loại thực thể và 7 nhãn.

- PER_LOC_FIX: Thực hiện tương tự như PER_LOC. Tuy nhiên chúng tôi nhận thấy rằng trong rất nhiều tên tổ chức (nhãn ORG), chúng chứa tên địa điểm (ví dụ "Câu lạc bộ bóng đá thành phố Hà Nội"). Do đó ở chiến lược này, chúng tôi xét tất cả các tên tổ chức, nếu các từ tương ứng trong những tên là tên của các quận, huyện, tỉnh, thành phố ở Việt Nam thì gán nhãn các từ này về nhãn LOC, ngược lại chúng được gán nhãn O. Ví dụ, với tên tổ chức (đã tách từ) "Câu lạc bộ bóng đá thành phố Hà Nội" thì các từ "Câu lạc bộ" và "bóng đá" được gán nhãn O, từ "thành phố" được gán nhãn B-LOC, từ "Hà Nội" được gán nhãn I-LOC. Việc phát hiện ra các tên địa điểm nằm trong tên tổ chức dựa vào tập hợp tên các quận, huyện, tỉnh, thành phố ở Việt Nam mà chúng tôi được cung cấp từ Trung tâm Không gian mạng Viettel. Như vậy chiến lược gán nhãn này cũng chỉ có 2 loại thực thể và 5 nhãn.

Khi so sánh kết quả các mô hình với các chiến lược gán nhãn khác nhau trên bộ dữ liệu kiểm thử, chúng tôi chỉ giữ lại các loại thực thể PER và LOC mà mô hình dự đoán được, các loại thực thể khác mà mô hình dự đoán (khi được huấn luyện ở các chiến lược ALL, PER_LOC_MISC) sẽ được chuyển toàn bộ về nhãn O.

5.3 Cài đặt

Chúng tôi tiến hành thực nghiệm với hai mô hình PhoBERT-CRF và VTCC-RoBERTa-CRF, gồm 12 tầng Transformer, 12 head attention và biểu diễn đầu ra cho các token là 768 chiều. So sánh một số điểm khác biệt giữa hai mô hình được trình bày trong bảng 3.

Các mô hình được huấn luyện với thuật toán tối ưu AdamW với tỉ lệ học là $1e - 5$, kích thước

mỗi batch là 64, trên GPU NVIDIA Tesla V100-SXM2. Quá trình huấn luyện sẽ dừng lại nếu kết quả của mô hình không cải thiện sau 5 epoch.

Bảng 3: So sánh giữa PhoBERT và VTCC-RoBERTa

	PhoBERT	VTCC-RoBERTa
Số lượng tham số	135M	173M
Dữ liệu huấn luyện	20GB	70GB
Độ dài lớn nhất	256	512

5.4 Kết quả nhận dạng thực thể

Chúng tôi kiểm thử các mô hình trên bộ dữ liệu kiểm thử đã xây dựng sử dụng độ đo Micro-F1. Kết quả được thống kê trong bảng 2, trong đó LM-LSTM-CRF là mô hình nhận dạng thực thể có tên được Trung tâm Không gian mạng Viettel xây dựng trước đó, và chỉ được huấn luyện với chiến lược gán nhãn ALL.

So sánh giữa các mô hình: Kết quả cho thấy khi giữ nguyên tất cả các nhãn từ dữ liệu gốc thì mô hình LM-LSTM-CRF cho kết quả cao nhất. Tuy nhiên, khi thay đổi các nhãn dữ liệu với từng chiến lược để huấn luyện thì mô hình VTCC-RoBERTa-CRF luôn đạt kết quả cao nhất. Nguyên nhân là mô hình ngôn ngữ VTCC-RoBERTa được huấn luyện với kích thước dữ liệu lớn hơn gấp hơn 3 lần so với mô hình ngôn ngữ PhoBERT và dữ liệu huấn luyện của VTCC-RoBERTa đến từ nhiều miền, trong đó có miền dữ liệu pháp luật. Do đó, mô hình VTCC-RoBERTa-CRF dễ dàng đưa ra các bộ trọng số tối ưu cho việc nhận dạng thực thể.

So sánh giữa các chiến lược: Hai chiến lược gán nhãn chỉ tập trung vào các thực thể mà bài toán yêu cầu dự đoán (PER và LOC) cho kết quả tốt hơn các chiến lược gán nhãn còn lại. Có thể thấy khi huấn luyện mô hình với đầu ra đơn giản hơn, phù hợp hơn với bài toán sẽ cho kết quả tốt hơn. Trong đó, chiến lược PER_LOC_FIX cho kết quả tốt nhất. Điều này thể hiện rõ khi mô hình huấn luyện với chiến lược này có thể dự đoán được những tên thực thể địa điểm xuất hiện bên trong những thực thể là tổ chức. Ví dụ

với xâu "Tòa án Nhân dân quận Ba Đình", mô hình khi huấn luyện với chiến lược ALL đưa ra dự đoán đây là thực thể ORG, với chiến lược PER_LOC và PER_LOC_MISC đưa ra dự đoán là thực thể MISC hoặc O, còn với chiến lược PER_LOC_FIX, mô hình dự đoán xâu "quận Ba Đình" là thực thể LOC.

Từ các kết quả trên, chúng tôi lựa chọn mô hình đạt kết quả cao nhất là VTCC-RoBERTa-CRF huấn luyện với chiến lược PER_LOC_FIX cho giai đoạn (1) của bài toán và làm đầu vào cho giai đoạn (2).

5.5 Kết quả mã hóa


Chúng tôi đã xây dựng một API cho phép người dùng thực hiện mã hóa tên người và địa điểm trong một bản án theo yêu cầu của bài toán từ những mô hình và phương pháp mà chúng tôi đã trình bày ở phía trên. API này đã được gửi cho nhóm phân tích nghiệp vụ tại Trung tâm Không gian mạng Viettel để kiểm tra độ hiệu quả với một số văn bản. Bảng 4 trình bày kết quả mà API trả về.

Hai văn bản đầu vào đầu tiên chỉ chứa các thông tin về những người có nhiệm vụ xét xử vụ án như Thẩm phán, Thư ký,... Có thể thấy với các thuật toán mà chúng tôi đã trình bày ở phần 4.2, API hoạt động tốt trên những ví dụ này khi không mã hóa tên và địa chỉ của họ. Với hai văn bản đầu vào tiếp theo chứa thông tin của những đối tượng trong vụ án, API cũng hoạt động tốt khi mã hóa chính xác các tên người và địa chỉ theo yêu cầu đề ra của bài toán. Trong đó ở văn bản cuối cùng, hai tên người "Phan Đăng Ngọc" và "Đỗ Hoài Nam" khi mã hóa cũng đã được phân biệt, tương ứng là "N" và "N1".


6 Đóng gói sản phẩm

Với kết quả như trên, API đã được xét duyệt và đóng gói thành một chức năng mới, được tích hợp vào sản phẩm Trợ lý ảo tòa án của Trung tâm Không gian mạng Viettel. Hình 2 và hình 3 minh họa giao diện API của phương pháp mà chúng tôi đề xuất.

Hiện tại, chức năng này đang trong giai đoạn kiểm thử từ nhóm phân tích nghiệp vụ của sản phẩm. Do đó, chúng tôi vẫn đang trong quá hậu xử lý để đưa ra những kết quả phù hợp hơn, dựa theo nhu cầu của sản phẩm.



Hình 2: Minh họa API (1)



Hình 3: Minh họa API (2)

7 Kết luận và Hướng phát triển

Trong báo cáo này, chúng tôi đã xây dựng thành công API phiên bản đầu tiên cho bài toán mã hóa tên người và địa điểm trong bản án. Chúng tôi đã tận dụng lại nguồn dữ liệu đã được gán nhãn trước đó ở những miền dữ liệu khác, đồng thời thay đổi chiến lược gán nhãn dữ liệu để huấn luyện được các mô hình phát hiện tên người và địa chỉ phù hợp với bài toán, khắc phục được hạn chế không có dữ liệu huấn luyện. Các mô hình và chiến lược gán nhãn dữ liệu ở giai đoạn (1) của bài toán mà chúng tôi đề xuất đã đạt những kết quả tốt hơn so với mô hình LM-LSTM-CRF cho bài toán Nhận dạng thực thể có tên mà Trung tâm Không gian mạng Viettel đã xây dựng trước đó trên tập dữ liệu kiểm thử. Đồng thời, các thuật toán mã hóa tên người và địa điểm mà chúng tôi đề xuất cũng hoạt động tương đối tốt trong nhiều trường hợp, phù hợp với các yêu cầu mà bài toán đặt ra.

Trong thời gian tới, chúng tôi sẽ khắc phục và cải thiện những trường hợp mà API còn hoạt động chưa tốt từ những phản hồi của nhóm phân tích nghiệp vụ của bài toán. Cùng với đó chúng tôi sẽ tiếp tục nghiên cứu các mô hình khác cho bài toán nhận dạng thực thể có tên, cũng như nghiên cứu áp dụng bài toán liên kết thực thể nhằm cải thiện độ chính xác việc mã hóa.

Bảng 4: Một số đầu vào và đầu ra tương ứng

Đầu vào	Đầu ra	Thời gian (ms)
Với Hội đồng giám đốc thẩm gồm có mười bốn thành viên tham gia xét xử, do ông Nguyễn Sơn , Phó Chánh án Tòa án nhân dân tối cao làm Chủ tọa phiên tòa, theo sự ủy quyền của Chánh án Tòa án nhân dân tối cao. Đại diện Viện kiểm sát nhân dân tối cao tham gia phiên tòa là bà Nguyễn Thị Yến , Kiểm sát viên Viện kiểm sát nhân dân tối cao. Thư ký ghi biên bản phiên tòa là bà Nguyễn Thị Hoa Mai , Thư ký Tòa án nhân dân tối cao.	Với Hội đồng giám đốc thẩm gồm có mười bốn thành viên tham gia xét xử, do ông Nguyễn Sơn , Phó Chánh án Tòa án nhân dân tối cao làm Chủ tọa phiên tòa, theo sự ủy quyền của Chánh án Tòa án nhân dân tối cao. Đại diện Viện kiểm sát nhân dân tối cao tham gia phiên tòa là bà Nguyễn Thị Yến , Kiểm sát viên Viện kiểm sát nhân dân tối cao. Thư ký ghi biên bản phiên tòa là bà Nguyễn Thị Hoa Mai , Thư ký Tòa án nhân dân tối cao.	340
Thành phần Ủy ban Thẩm phán Tòa án nhân dân cấp cao gồm có: Phó Chánh án-Chủ tọa phiên tòa: Bà Lê Thị Ngọc Hà . Các thành viên Hội đồng giám đốc thẩm: Ông Nguyễn Văn Dũng và ông Phạm Việt Cường . Thư ký phiên tòa: Bà Trần Thị Tố Nga . Thư ký Tòa án. Đại diện Viện kiểm sát nhân dân cấp cao tại Đà Nẵng tham gia phiên tòa: Ông Đoàn Minh Lộc -Kiểm sát viên	Thành phần Ủy ban Thẩm phán Tòa án nhân dân cấp cao gồm có: Phó Chánh án-Chủ tọa phiên tòa: Bà Lê Thị Ngọc Hà . Các thành viên Hội đồng giám đốc thẩm: Ông Nguyễn Văn Dũng và ông Phạm Việt Cường . Thư ký phiên tòa: Bà Trần Thị Tố Nga . Thư ký Tòa án. Đại diện Viện kiểm sát nhân dân cấp cao tại Đà Nẵng tham gia phiên tòa: Ông Đoàn Minh Lộc -Kiểm sát viên	326
Ngày 03 tháng 3 năm 2021, tại trụ sở Tòa án nhân dân tối cao mở phiên tòa giám đốc thẩm xét xử vụ án hình sự đối với: Phan Đăng Trường , sinh năm 1986; trú tại cụm 7, thôn Triệu Xuyên, xã Long Xuyên, huyện Phúc Thọ, thành phố Hà Nội ; trình độ học vấn: lớp 12/12; nghề nghiệp: lao động tự do; có vợ và 02 con; tiền án, tiền sự: không; bị bắt giam từ ngày 11/10 đến ngày 21/12/2017.	Ngày 03 tháng 3 năm 2021, tại trụ sở Tòa án nhân dân tối cao mở phiên tòa giám đốc thẩm xét xử vụ án hình sự đối với: Phan Đăng T , sinh năm 1986; trú tại cụm X, thôn T, xã L, huyện P, thành phố H ; trình độ học vấn: lớp 12/12; nghề nghiệp: lao động tự do; có vợ và 02 con; tiền án, tiền sự: không; bị bắt giam từ ngày 11/10 đến ngày 21/12/2017.	409
Khoảng 09 giờ 30 phút ngày 11/10/2017, tổ công tác Phòng Cảnh sát kinh tế, Phòng Cảnh sát môi trường, Công an thành phố Hà Nội phát hiện xe ô tô tải biển kiểm soát 29C-565.77 đang đỗ tại cổng Công ty cổ phần CP Việt Nam, địa chỉ tại tổ 2, khu Tân Mai, thị trấn Xuân Mai, huyện Chương Mỹ, thành phố Hà Nội có biểu hiện nghi vấn. Qua kiểm tra, xác định trên xe ô tô có Phan Đăng Ngọc và lái xe là Đỗ Hoài Nam , xe chở 1.039 ồng nhựa mang nhãn hiệu “TIEN PHONG”. Phan Đăng Ngọc và Đỗ Hoài Nam không xuất trình được hóa đơn, chứng từ chứng minh nguồn gốc xuất xứ của số ồng nhựa trên. Cơ quan điều tra đã tiến hành khám xét khẩn cấp nơi ở, địa điểm các kho hàng của Phan Đăng Ngọc và thu giữ 1.620 ồng nhựa mang nhãn hiệu “TIEN PHONG”. Tại bản Kết luận giám định số 6158/KLGD-PC54(Đ4) ngày 02/11/2017, Phòng kỹ thuật hình sự Công an thành phố Hà Nội kết luận: các chi tiết logo TIEN PHONG và “ONG NHUA TIEN PHONG” trên 2.659 ồng nhựa nhãn hiệu “TIEN PHONG” thu giữ của Phan Đăng Ngọc với các chi tiết in logo TIEN PHONG và “ONG NHUA TIEN PHONG” trên các ồng nhựa mang nhãn hiệu “TIEN PHONG” do Công ty Cổ phần Nhựa Thiếu niên Tiền Phong sản xuất là không phải do cùng một bản in in ra. Căn cứ bảng giá sản phẩm ồng nhựa ban hành theo Quyết định số 46 có hiệu lực từ ngày 01/9/2016, Công ty Cổ phần Nhựa Thiếu niên Tiền Phong xác định: giá trị hàng thật (ồng nhựa nhãn hiệu “TIEN PHONG” do Công ty Cổ phần Nhựa Thiếu niên Tiền Phong đăng ký bảo hộ, sản xuất, phân phối) tương đương với số hàng giả mà Cơ quan điều tra thu giữ của Phan Đăng Ngọc có giá trị tại thời điểm ngày 11/10/2017 là 405.843.460 đồng. Quá trình điều tra xác định hành vi phạm tội của Phan Đăng Ngọc cụ thể như sau: tháng 9/2017, Ngọc thấy ồng nhựa nhãn hiệu “Asico” của Công ty Cổ phần Nhựa Á Châu có giá chưa bằng ½ so với giá ồng nhựa nhãn hiệu “TIEN PHONG”.	Khoảng 09 giờ 30 phút ngày 11/10/2017, tổ công tác Phòng Cảnh sát kinh tế, Phòng Cảnh sát môi trường, Công an thành phố H phát hiện xe ô tô tải biển kiểm soát 29C - 565.77 đang đỗ tại cổng Công ty cổ phần CP Việt Nam, địa chỉ tại tổ X, khu T, thị trấn X, huyện C, thành phố H có biểu hiện nghi vấn. Qua kiểm tra, xác định trên xe ô tô có Phan Đăng N và lái xe là Đỗ Hoài N1 , xe chở 1.039 ồng nhựa mang nhãn hiệu “ TIEN PHONG ”. Phan Đăng N và Đỗ Hoài N1 không xuất trình được hoá đơn, chứng từ chứng minh nguồn gốc xuất xứ của số ồng nhựa trên. Cơ quan điều tra đã tiến hành khám xét khẩn cấp nơi ở, địa điểm các kho hàng của Phan Đăng N và thu giữ 1.620 ồng nhựa mang nhãn hiệu “ TIEN PHONG ”. Tại bản Kết luận giám định số 6158 / KLGD-PC54 (Đ4) ngày 02/11/2017, Phòng kỹ thuật hình sự Công an thành phố H kết luận: các chi tiết logo TIEN PHONG và “ ONG NHUA TIEN PHONG ” trên 2.659 ồng nhựa nhãn hiệu “ TIEN PHONG ” thu giữ của Phan Đăng N với các chi tiết in logo TIEN PHONG và “ ONG NHUA TIEN PHONG ” trên các ồng nhựa mang nhãn hiệu “ TIEN PHONG ” do Công ty Cổ phần Nhựa Thiếu niên Tiền Phong sản xuất là không phải do cùng một bản in in ra. Căn cứ bảng giá sản phẩm ồng nhựa ban hành theo Quyết định số 46 có hiệu lực từ ngày 01/9/2016, Công ty Cổ phần Nhựa Thiếu niên Tiền Phong xác định: giá trị hàng thật (ồng nhựa nhãn hiệu “ TIEN PHONG ” do Công ty Cổ phần Nhựa Thiếu niên Tiền Phong đăng ký bảo hộ, sản xuất, phân phối) tương đương với số hàng giả mà Cơ quan điều tra thu giữ của Phan Đăng N có giá trị tại thời điểm ngày 11/10/2017 là 405.843.460 đồng. Quá trình điều tra xác định hành vi phạm tội của Phan Đăng N cụ thể như sau: tháng 9/2017, N thấy ồng nhựa nhãn hiệu “ Asico ” của Công ty Cổ phần Nhựa Á Châu có giá chưa bằng ½ so với giá ồng nhựa nhãn hiệu “ TIEN PHONG ”.	578

Tài liệu tham khảo

- Jason PC Chiu and Eric Nichols. 2016. Named entity recognition with bidirectional lstm-cnns. *Transactions of the association for computational linguistics*, 4:357–370.
- Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. 2019. [BERT: Pre-training of deep bidirectional transformers for language understanding](#). In *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long and Short Papers)*, pages 4171–4186, Minneapolis, Minnesota. Association for Computational Linguistics.
- Zhiheng Huang, Wei Xu, and Kai Yu. 2015. Bidirectional lstm-crf models for sequence tagging. *arXiv preprint arXiv:1508.01991*.
- Liyuan Liu, Jingbo Shang, Xiang Ren, Frank Xu, Huan Gui, Jian Peng, and Jiawei Han. 2018. Empower sequence labeling with task-aware neural language model. In *Proceedings of the AAAI Conference on Artificial Intelligence*, volume 32.
- Yinhan Liu, Myle Ott, Naman Goyal, Jingfei Du, Mandar Joshi, Danqi Chen, Omer Levy, Mike Lewis, Luke Zettlemoyer, and Veselin Stoyanov. 2019. Roberta: A robustly optimized bert pretraining approach. *arXiv preprint arXiv:1907.11692*.
- Andrew McCallum and Wei Li. 2003. Early results for named entity recognition with conditional random fields, feature induction and web-enhanced lexicons.
- Dat Quoc Nguyen and Anh-Tuan Nguyen. 2020. Phobert: Pre-trained language models for vietnamese. In *Findings of the Association for Computational Linguistics: EMNLP 2020*, pages 1037–1042.
- Fábio Souza, Rodrigo Nogueira, and Roberto Lotufo. 2019. Portuguese named entity recognition using bert-crf. *arXiv preprint arXiv:1909.10649*.
- GuoDong Zhou and Jian Su. 2002. Named entity recognition using an hmm-based chunk tagger. In *Proceedings of the 40th annual meeting of the association for computational linguistics*, pages 473–480.